


Daniel López Arenas

Análisis de Datos de un TFM



CRÉDITOS Y CONTEXTO DEL MATERIAL

Material elaborado por: Daniel López Arenas

Actividad: Clases particulares

Entidad organizadora: Actividad independiente

Fecha: Enero, 2023

Tipo de docencia: Docencia no oficial

Licencia: CC BY-NC-SA 4.0 Este material puede reutilizarse y citarse con fines no comerciales, indicando autoría, bajo la misma licencia.


Link: <https://github.com/Danlopare/Material-Docente-Original/tree/main> (Archivo "MPGS 22-23 Análisis de Datos para TFM")

Índice de Contenidos

1. Lógica interna
2. Análisis exploratorio de los datos
3. Supuestos estadísticos
4. Análisis exploratorio de las correlaciones
5. Pruebas no paramétricas
6. Pruebas paramétricas
7. Mediación y Moderación

Lógica interna

(si es que existe)



FMP, DAD-I, DAD-II y Psicometría en una ecuación



$$\text{Efecto} = \text{Modelo} + \text{Error de medida}$$

Análisis Exploratorio de los Datos

Frecuencia


Simetría

Kurtosis

**Tendencia
central**

Dispersión

Outliers



Análisis Exploratorio de los Datos: Outliers

En SPSS: [Analizar > Estadísticos descriptivos > Descriptivos > Meter variables de interés (las escalares) y seleccionar la opción “Guardar valores estandarizados como variables”]

En un Mundo Ideal:

Cualquier participante con unas puntuaciones $Z > |2,5| \rightarrow$ **ADIOS**

Probablemente te tendrás que resignar a cumplir:

94% de la muestra por debajo de $Z = |1,96|$

5% de la muestra por debajo de $Z = |2,58|$

1% de la muestra por debajo de $Z = |3,29|$

NADA por encima de $Z = |3,29|$

A partir de aquí, continuamos trabajando con las puntuaciones **Z**

AnsConf	ZAnsConf
31,00	-,92960
31,00	-,92960
30,00	-1,11368
30,00	-1,11368
30,00	-1,11368
30,00	-1,11368
30,00	-1,11368
30,00	-1,11368
30,00	-1,11368
29,00	-1,29776
29,00	-1,29776
29,00	-1,29776
29,00	-1,29776
29,00	-1,29776
28,00	-1,48184
28,00	-1,48184
27,00	-1,66592
27,00	-1,66592
26,00	-1,85000
26,00	-1,85000
24,00	-2,21815
22,00	-2,58631
21,00	-2,77039
21,00	-2,77039
21,00	-2,77039
21,00	-2,77039
20,00	-2,95447

Análisis Exploratorio de los Datos: **Frecuencias**

[*Descriptivos* (Añadir todas las variables escalares en “*Variables*” y las Variables categóricas de una en una en “*Separar*”) > *Tablas* > *Selecciona Tablas de frecuencias*]

VARIABLES CATEGÓRICAS										
Género			Estudios			Formación				
Hombre	Mujer	No binario	ESO/FPGM	BACH/FPGS	Universidad	Estudiante	Parado	Empleado	Autónomo	Otros

Interesan grupos parejos.

Si no, no hay que descartar agrupar la muestra por valores de las Variables Categóricas, pero hay que tener en cuenta la descompensación de los grupos.

OJO:

Si nos interesa alguna agrupación, seguir mirando Simetría, Kurtosis, Tendencia central y Dispersión de la **muestra en general**, pero también de los **grupos** en los que se divide la muestra.

Análisis Exploratorio de los Datos: **Simetría**

[*Descriptivos* (Añadir todas las variables escalares en “*Variables*” y las Variables categóricas de 1 en 1 en “*Separar*”) > *Estadísticos* > *Distribución* > *Asimetría*]

Con numeritos:

	Edad		Agre		AnsCog		AnsSom		AnsConf	
	Hombre	Mujer	Hombre	Mujer	Hombre	Mujer	Hombre	Mujer	Hombre	Mujer
Válido	90	90	90	90	90	90	90	90	90	90
Asimetría	0.300	0.089	0.412	0.021	-0.438	-0.269	-0.213	-0.100	-0.691	-0.239
Error Típico de la Asimetría	0.254	0.254	0.254	0.254	0.254	0.254	0.254	0.254	0.254	0.254

$IC (95\%) = 0,300 \pm 0,254 \rightarrow (0,046 , 0,554)$

NO contiene el ‘Cero’ → **ASIMETRÍA**

Valor del estadístico → Positivo

ASIMETRÍA POSITIVA


$IC (95\%) = -0,213 \pm 0,254 \rightarrow (-0,467 , 0,041)$

SÍ contiene el ‘Cero’ → **SIMETRÍA**

Análisis Exploratorio de los Datos: **Simetría**

[*Descriptivos* (Añadir todas las variables escalares en “*Variables*” y las Variables categóricas de 1 en 1 en “*Separar*”) > *Gráficos básicos* > *Gráfico de distribuciones*]

Con dibujitos:



Regla mnemotécnica: *La cola apunta hacia lo que es.*

Análisis Exploratorio de los Datos: Kurtosis

[*Descriptivos* (Añadir todas las variables escalares en “Variables” y las Variables categóricas de 1 en 1 en “Separar”) > *Estadísticos* > *Distribución* > *Kurtosis*]

Con numeritos:

	Edad		Agre		AnsCog		AnsSom		AnsConf	
	Hombre	Mujer	Hombre	Mujer	Hombre	Mujer	Hombre	Mujer	Hombre	Mujer
Válido	90	90	90	90	90	90	90	90	90	90
Curtosis	-0.530	-0.900	-0.459	-0.553	0.886	-0.064	-0.451	-0.557	0.365	0.111
Error Típico de la Curtosis	0.503	0.503	0.503	0.503	0.503	0.503	0.503	0.503	0.503	0.503

IC (95%) = $-0,530 \pm 0,503 \rightarrow (-1,033, -0,027)$

NO contiene el ‘Cero’ → **KURTOSIS**

Valor del estadístico → NEGATIVO

PLATIKURTOSIS


IC (95%) = $-0,451 \pm 0,503 \rightarrow (-0,467, 0,041)$

SÍ contiene el ‘Cero’ → **MESOKURTOSIS**

Análisis Exploratorio de los Datos: **Kurtosis**

[*Descriptivos* (Añadir todas las variables escalares en “Variables” y las Variables categóricas de 1 en 1 en “Separar”) > *Gráficos básicos* > *Gráfico de distribuciones*]

Con dibujitos:



Regla mnemotécnica: “Plati” es como “plato” (llano) y “Meso” significa “Medio”, así que el restante (Lepto) implica “apuntamiento”

Análisis Exploratorio de los Datos:

Tendencia central y Dispersión

[Descriptivos (Añadir todas las variables escalares) > Estadísticos > Tamaño de la muestra (Selecciona Válido), Cuantiles (Selecciona Cuartiles), Tendencia central (selecciona todo), Distribución (Selecciona Asimetría y Kurtosis) y Dispersión (Selecciona Desviación típica, IQR, Varianza, Rango, Mín y Máx)]

Con numeritos:

Las medidas de **tendencia central** son:

Moda
Mediana
Media

Las medidas de **dispersión** son:

Cuantil (Cuartil y Percentil, sobre todo)
Rango
Rango intercuartil
Desviación típica

	Edad		Agre		AnsCog		AnsSom		AnsConf	
	Hombre	Mujer	Hombre	Mujer	Hombre	Mujer	Hombre	Mujer	Hombre	Mujer
Moda	14.000	16.000	24.000	21.000	29.000	27.000	25.000	29.000	36.000	35.000
Mediana	14.000	16.000	24.000	21.500	30.000	28.500	27.000	25.500	36.000	36.000
Media	13.767	16.578	23.478	22.456	30.300	28.589	26.389	24.578	35.778	36.322
RIC(IQR)	1.000	2.000	12.000	9.750	7.000	8.000	11.000	9.750	8.000	5.750
Rango	4.000	5.000	33.000	29.000	35.000	28.000	32.000	32.000	25.000	23.000
Mínimo	12.000	14.000	11.000	9.000	10.000	13.000	9.000	9.000	20.000	22.000
Máximo	16.000	19.000	44.000	38.000	45.000	41.000	41.000	41.000	45.000	45.000
25th percentile	13.000	16.000	17.000	18.000	27.000	25.000	21.000	19.250	32.000	34.000
50th percentile	14.000	16.000	24.000	21.500	30.000	28.500	27.000	25.500	36.000	36.000
75th percentile	14.000	18.000	29.000	27.750	34.000	33.000	32.000	29.000	40.000	39.750


Al contrario que con la Asimetría y la Curtosis, esto se ve mejor con dibujitos

Análisis Exploratorio de los Datos:

Tendencia central y **Dispersión**

[Descriptivos (Añadir todas las variables escalares) > Gráficos personalizables > Diagrama de caja > Selecciona Diagrama de caja y Etiquetar valores atípicos].

Con dibujitos:



Análisis Exploratorio de los Datos:


Tendencia central y Dispersión

[Descriptivos (Añadir todas las variables escalares) > Gráficos personalizables > Diagrama de caja > Selecciona Diagrama de caja y Etiquetar valores atípicos].

Con dibujitos:

Misma tendencia central (Medianas)

Distinta dispersión (Rangos)



Análisis Exploratorio de los Participantes:

Análisis de Clusters

[En SPSS: Analizar > Clasificar > Cluster bietápico > Vuelca todas las variables continuas en “Variables continuas”]

Clústeres											
Importancia de entrada (predictor)											
	1,0		0,8		0,6		0,4		0,2		0,0
Clúster	3			2			1				
Etiqueta											
Descripción											
Tamaño	44,4%			40,6%			15,0%				
	(80)			(73)			(27)				
Entradas	Ansiedad 28,88			Ansiedad 18,92			Ansiedad 33,19				
	Agresividad 23,61			Agresividad 29,41			Agresividad 30,67				
	Edad 15,38			Edad 15,49			Edad 13,70				

Supuestos Estadísticos

Realizaremos una prueba paramétrica, e incluso un análisis de regresión si:

- Los residuos de las puntuaciones se distribuyen de forma similar a la distribución normal.

Ho: NO EXISTEN diferencias significativas entre la distribución de las puntuaciones y la distribución normal

Nos interesa **ACEPTARLA** ($p > 0,05$)

- La varianza de las puntuaciones son relativamente homogéneas.

Ho: NO EXISTEN diferencias significativas entre las varianzas de las puntuaciones

Nos interesa **ACEPTARLA** ($p > 0,05$)

- Los residuos de las puntuaciones no se relacionan linealmente entre sí.

Ho: NO EXISTE correlación significativa entre los residuos


Nos interesa **ACEPTARLA**

Supuestos Estadísticos:

Normalidad

[*Descriptivos* (Añadir todas las variables escalares en “Variables” y las Variables categóricas de una en una en “Separar”) > *Gráficos básicos* > *Gráficos Q-Q*]

Con dibujitos:



Supuestos Estadísticos:

Normalidad

[*Descriptivos* (Añadir todas las variables escalares en “*Variables*” y las Variables categóricas de una en una en “*Separar*”) > *Estadísticos* > *Distribución* > *Contraste de Shapiro-Wilk*]

Con numeritos:

Estadísticos Descriptivos

	Edad	Agre	AnsCog	AnsSom	AnsConf
Shapiro-Wilk	0.945	0.983	0.984	0.986	0.963
Valor de p de Shapiro-Wilk	< .001	0.030	0.037	0.071	< .001

Supuestos Estadísticos:

Homocedasticidad

[*Contrastes T > Contraste T para Muestras Independientes > Incluye las VV continuas en “Variables Dependientes” y la Variable Categórica en “Variable de agrupación” > Verificación de Supuestos > Igualdad de varianzas > De Levene*]

Contraste de Igualdad de Varianzas (de Levene) ▼

	F	df ₁	df ₂	p
Edad	8.558	1	178	0.004
Agre	2.691	1	178	0.103
AnsCog	0.009	1	178	0.925
AnsSom	0.172	1	178	0.679
AnsConf	2.327	1	178	0.129

Supuestos Estadísticos:

Independencia de errores

[Regresión > Regresión lineal > Selecciona una VD continua y el resto de VV continuas en “Covariables”> Estadísticos > Errores > Durbin-Watson]

Resumen del Modelo - Agre

Modelo	R	R²	R² Ajustado	RMSE	Durbin-Watson		
					Autocorrelación	Estadístico	p
1	0.284	0.080	0.065	7.209	0.180	1.631	0.012
2	0.282	0.080	0.069	7.192	0.178	1.635	0.013
3	0.274	0.075	0.070	7.189	0.187	1.617	0.010

Aceptamos la H_0 (no hay correlación significativa entre los residuos de las variables) si el estadístico de D-W se encuentra dentro del intervalo (1'5 , 2'5).

Si no cumples este supuesto, cierra el PC y tíralo por la ventana, porque se te cae el chiringuito PERO BIEN.

Análisis Exploratorio de las Correlaciones

[Regresión > Correlación > Vuelca todas las variables en “Variables” > Coeficiente de correlación muestral (R de Pearson o Rho de Spearman) y Opciones adicionales (Marcar correlaciones significativas)]

Tabla de Correlación

Variable		Edad	Género	Agre	AnsCog	AnsSom	AnsConf
1. Edad	R de Pearson	—					
	Rho de Spearman	—					
2. Género	R de Pearson	0.722***	—				
	Rho de Spearman	0.742***	—				
3. Agre	R de Pearson	-0.197**	-0.069	—			
	Rho de Spearman	-0.188*	-0.041	—			
4. AnsCog	R de Pearson	-0.160*	-0.131	0.274***	—		
	Rho de Spearman	-0.160*	-0.141	0.240**	—		
5. AnsSom	R de Pearson	-0.141	-0.120	0.218**	0.600***	—	
	Rho de Spearman	-0.149*	-0.115	0.205**	0.564***	—	
6. AnsConf	R de Pearson	0.007	0.050	-0.003	-0.041	-0.264***	—
	Rho de Spearman	-0.021	0.014	-0.040	-0.015	-0.290***	—

* p < .05, ** p < .01, *** p < .001

¿Qué prueba uso?

¿Cuántos grupos se forman?

2 grupos

3 ó más

**¿Se cumplen los
supuestos
estadísticos?**

Sí

t de Student

ANOVA

No

*U de Mann-
Whitney*

Kruskal-Wallis

Pruebas No-Paramétricas para Dos condiciones (grupos) independientes: U de Mann-Whitney

[Contrastes T > Contraste T para Muestras Independientes > Incluye las VV continuas en “Variables Dependientes” y la Variable Categórica en “Variable de agrupación” > Contrastes (Mann-Whitney) y Magnitud del efecto (D de Cohen)]

Contraste T para Muestras Independientes			Esta es la diferencia entre las medias			
	W	gl	p	Estimación de Hodges-Lehmann	Correlación de Rango Biserial	ET Correlación de Rango Biserial
Edad	627.000		< .001	-3.000	-0.845	0.086
Agre	4243.000		0.581	1.000	0.048	0.086
AnsCog	4706.500		0.060	(Es Grupo 1 – Grupo 2) 2.000	0.162	0.086
AnsSom	4587.500		0.124	2.000	0.133	0.086
AnsConf	3985.000		0.853	-3.005×10 ⁻⁵	-0.016	0.086

Nota. Para el contraste de Mann-Whitney, la magnitud del efecto viene dada por la correlación biserial de rangos.

Nota. Contraste U de Mann-Whitney.

Ofrece una respuesta tipo “La edad es significativamente mayor en el Grupo 2 (Mujeres) que en el Grupo 1 (Hombres)”

Pruebas No-Paramétricas para más de dos condiciones (grupos) independientes: Kruskal-Wallis

[ANOVA > ANOVA > Variable continua como “Dependiente” y VV Categóricas como “Factores Fijos” > Mostrar (Estimaciones de la magnitud del efecto > η^2), No Paramétricos (Contraste de Kruskal-Wallis) y Contrastes Post Hoc (Tipo “Estándar” y Corrección “Tukey”)]

Contraste de Kruskal-Wallis

Contraste de Kruskal-Wallis

Factor	Estadístico	gl	p
Estudios	3.307	2	0.191

Contrastes Post-hoc

Estándar

Comparaciones Post-hoc - Estudios

		Diferencia de Medias	ET	t	p _{Tukey}
(ESO/FPGM)	(Bach/FPGS)	-2.050	1.195	-1.715	0.202
	Universidad	-0.783	1.195	-0.655	0.790
(Bach/FPGS)	Universidad	1.267	1.195	1.060	0.540

Nota. Valor p ajustado para comparar una familia de 3

Y si tengo (como en este caso) 3 grupos, ¿por qué no los comparo por pares con la U de Mann-Whitney?

Pruebas Paramétricas para Dos condiciones (grupos) independientes: *t* de Student

[*Contrastes T > Contraste T para Muestras Independientes > Incluye las VV continuas en “Variables Dependientes” y la Variable Categórica en “Variable de agrupación” > Contrastes (Student) y Magnitud del efecto (D de Cohen)*]

Contraste T para Muestras Independientes

	t	gl	p	Diferencia de Medias	Diferencia del Error Típico	D de Cohen	ET D de Cohen
Edad	-13.933	178	< .001*	-2.811	0.202	-2.077	0.215
Agre	0.920	178	0.359	1.022	1.112	0.137	0.149
AnsCog	1.759	178	0.080	1.711	0.973	0.262	0.150
AnsSom	1.616	178	0.108	1.811	1.121	0.241	0.150
AnsConf	-0.671	178	0.503	-0.544	0.811	-0.100	0.149

Nota. Contraste t de Student.

Pruebas Paramétricas para más de Dos condiciones (grupos) independientes: ANOVA

[ANOVA > ANOVA > Variable continua como “Dependiente” y VV Categóricas como “Factores Fijos” > *Mostrar (Estimaciones de la magnitud del efecto > η^2) y Contrastes post-hoc (Selecciona Tukey y Scheffé)*]

ANOVA - Edad

Casos	Suma de Cuadrados	gl	Cuadrado Medio	F	p	η^2
Estudios	4.078	2	2.039	0.533	0.588	0.006
Residuals	677.583	177	3.828			

Nota. Suma de Cuadrados Tipo III

Contrastes Post-hoc

Estándar

Comparaciones Post-hoc - Estudios

		Diferencia de Medias	ET	t	p _{Tukey}
(ESO/FPGM)	(Bach/FPGS)	-0.150	0.357	-0.420	0.907
	Universidad	-0.367	0.357	-1.026	0.561
(Bach/FPGS)	Universidad	-0.217	0.357	-0.607	0.817

Nota. Valor p ajustado para comparar una familia de 3

Modelo de Regresión Lineal:

Aprobar el examen se relaciona linealmente con aprobar la asignatura

**Asignatura con
punto de asistencia
y Examen Final:**

$$\text{Nota Asignatura} = 1 + 0'9 \cdot \text{Nota Examen}$$


**Asignatura con
punto de asistencia
y dos parciales:**

$$\text{Nota Asignatura} = 1 + 0'4 \cdot 1^{\text{er Parcial}} + 0'5 \cdot 2^{\text{o Parcial}}$$

Modelo de regresión:

$$Y = b_0 + b_1 \cdot X_1 + b_2 \cdot X_2$$

Modelo de Regresión Lineal: Haciendo un sandwich de correlaciones



Modelo de Regresión Lineal: Resumen del Modelo

[Regresión > Regresión lineal > Selecciona una VD continua y el resto de VV continuas en “Covariables” > Estadísticos > Coeficientes de Regresión > Seleccionamos “Estimaciones”, “Ajuste del modelo”, “Cambio en R cuadrado”, “Correlaciones part y parciales” y “Diagnóstico de colinealidad”].

Resumen del Modelo - Agre ▼

Modelo	R	R ²	R ² Ajustado	RMSE	Cambio en R ²	Cambio en F	gl1	gl2	p
1	0.321	0.103	0.083	7.139	0.103	5.031	4	175	< .001
2	0.320	0.102	0.087	7.122	-0.001	-0.141	1	176	1.000
3	0.315	0.099	0.089	7.115	-0.003	-0.650	1	177	1.000

ANOVA

Modelo		Suma de Cuadrados	gl	Cuadrado Medio	F	p
1	Regresión	1025.708	4	256.427	5.031	< .001
	Residuo	8920.092	175	50.972		
	Total	9945.800	179			
2	Regresión	1018.576	3	339.525	6.694	< .001
	Residuo	8927.224	176	50.723		
	Total	9945.800	179			
3	Regresión	985.680	2	492.840	9.736	< .001
	Residuo	8960.120	177	50.622		
	Total	9945.800	179			

De aquí sacamos el **% de varianza de la VD que es explicada por el modelo** y el proceso de construcción del modelo con el **método hacia atrás**.


Modelo de Regresión Lineal: Componentes del modelo

[Regresión > Regresión lineal > Selecciona una VD continua y el resto de VV continuas en “Covariables” > Estadísticos > Coeficientes de Regresión > Seleccionamos “Estimaciones”, “Ajuste del modelo”, “Cambio en R cuadrado”, “Correlaciones part y parciales” y “Diagnóstico de colinealidad”].

Modelo		No tipificado	Error Típico	Tipificado	t	p	Estadísticos de Multicolinealidad	
							Tolerancia	FIV
1	(Intercept)	21.640	6.630		3.264	0.001		
	AnsCog	0.229	0.103	0.201	2.214	0.028	0.620	1.613
	AnsSom	0.081	0.093	0.083	0.879	0.381	0.580	1.723
	AnsConf	0.039	0.103	0.028	0.374	0.709	0.908	1.101
	Edad	-0.585	0.278	-0.153	-2.106	0.037	0.971	1.030
2	(Intercept)	23.153	5.240		4.418	< .001		
	AnsCog	0.234	0.102	0.206	2.302	0.023	0.634	1.577
	AnsSom	0.071	0.088	0.072	0.805	0.422	0.638	1.568
	Edad	-0.586	0.277	-0.154	-2.119	0.036	0.971	1.030
3	(Intercept)	23.734	5.185		4.577	< .001		
	AnsCog	0.283	0.082	0.249	3.446	< .001	0.975	1.026
	Edad	-0.599	0.276	-0.157	-2.171	0.031	0.975	1.026

De aquí sacamos las **ecuaciones de regresión bruta y estandarizada**, y el **diagnóstico de Colinealidad** (con suerte, que no hay Colinealidad)

Mediación y Moderación




Mediación y Moderación


Un **Predictor del Modelo de Regresión** se convierte en **Mediador (Me)** cuando se cumple lo siguiente:

- El potencial mediador (Me) puede ser predicha por una variable que no forma parte de nuestro modelo de regresión (W) $W \xrightarrow{b_2 \neq 0} Me$


Si encontramos una variable ajena a nuestra regresión de partida (W) que se relacione con algún predictor de dicha regresión de partida, hacemos un análisis de regresión para predecir nuestra VD en base a dos predictores: Me y W



Si $b_W \neq 0 \rightarrow$ **Mediación Parcial**



Si $b_W = 0 \rightarrow$ **Mediación Total**






Moderación

Un **Predictor del Modelo de Regresión** se convierte en **Moderador (Mo)** cuando se cumple lo siguiente:

- El potencial moderador (Mo) puede ser predicha por una variable que **SÍ** forma parte de nuestro modelo de regresión (X_k) $X_k \xrightarrow{b \neq 0} Mo$
- La regresión de la VD con Mo, X_k y el producto de Mo y X_k ($Mo \cdot X_k$) como predictores muestra un coeficiente de regresión significativo para $Mo \cdot X_k$

$(Mo - \overline{Mo}) \cdot (X_k - \overline{X_k})$
En SPSS: [Transformar > Calcular variable]



Daniel López Arenas

Análisis de Datos de un TFM

